MTH101 · Chapitre 5

Estimation, intervalle de confiance, test de deux proportions

Adrien Chiodo

Octobre 2026

Comment travailler ce chapitre. Il accompagne la séance du vendredi 23 octobre après-midi, et paraît avant elle, avec le chapitre 4, « Loi normale et théorème central limite », dont il se sert. Il se suffit à lui-même : « Avant de commencer » rappelle ce qu'il prend au chapitre 4.

Le temps. Comptez environ quatre heures : deux heures pour les sections 1 et 2, crayon en main ; une heure pour les sections 3 à 5 ; une heure pour les exercices.

Les exercices sont corrigés dans un fascicule à part, « MTH101 · Chapitre 5 · Corrigés », aux mêmes numéros. Cherchez d'abord : un corrigé lu trop tôt n'apprend presque rien.

Python. Quelques calculs utilisent scipy.stats, déjà installé dans votre codespace. Sans ordinateur, une calculatrice et la table de la section 2.4 du chapitre 4 suffisent.

De l'aide. Une notion qui résiste : le kit tuteur du site du cours, ad-c.github.io/mth101, qui fait d'un assistant IA un tuteur. Une question qui reste : l'intervenant, adrien.chiodo@ecole-89.com.

Les chiffres de ce chapitre sont fictifs, sauf mention d'une source.

AVANT DE COMMENCER

Ce que le chapitre 4 a posé

- **La loi normale** $N(\mu ; \sigma)$: 95 % de ses valeurs sont à moins de 1,96 écart-type de sa moyenne. En Python, `norm.cdf(x, mu, sigma)` donne $P(X \leq x)$ et `norm.sf(x, mu, sigma)` donne $P(X \geq x)$.
- **Le théorème central limite** : la moyenne de n observations indépendantes, de même loi, d'écart-type σ, suit à peu près une loi normale d'écart-type $\sigma / \sqrt{n}$ quand n est assez grand.
- **Le cas d'une fréquence.** On observe n individus indépendants ; chacun a la probabilité p de présenter un caractère. La fréquence observée f, souvent notée $\hat{p}$, notamment dans les ouvrages en anglais, est une moyenne de 0 et de 1, et suit à peu près $N(p ; \sqrt{p(1 - p) / n})$.

Les calculs dont vous aurez besoin

- **Une fréquence** : 159 / 300 = 0,53, soit 53 %.
- **Des points ou des pour cent.** De 41 % à 53 %, la part gagne 12 points de pourcentage, 53 − 41 ; elle augmente d'environ 29 %, 12 / 41 ≈ 0,29. Ce chapitre compare des parts en points.
- **La racine d'un quotient** : $\sqrt{(0{,}5 \times 0{,}5 / 400)} = \sqrt{0{,}000625} = 0{,}025$.
- **Le signe ±.** « 0,455 ± 0,035 » désigne les deux bornes 0,455 − 0,035 et 0,455 + 0,035 : un intervalle, de 0,420 à 0,490.
- **Arrondir à la fin.** Gardez tous les chiffres pendant le calcul. Une proportion se donne en décimal arrondi au millième, ou en pourcentage à une décimale.

1. UN PRIX QUI VARIE SELON LA DEMANDE

Une chaîne d'hôtels, cliente de l'agence, pratique la tarification dynamique : le prix d'une chambre monte quand la demande est forte, et baisse quand elle faiblit. Elle veut savoir ce qu'en pensent ses clients. Elle a tiré au sort 800 clients de l'année et leur a demandé : « Trouvez-vous acceptable qu'un prix varie selon la demande ? »

	Clients interrogés	Réponse « acceptable »	Part
Voyage d'affaires	300	159	53 %
Voyage de loisirs	500	205	41 %
Ensemble	800	364	45,5 %

Chiffres fictifs. La chaîne pose deux questions.

1. **Quelle part de tous ses clients** juge acceptable un prix variable ? Elle n'en a interrogé que 800, parmi des dizaines de milliers.
2. **Les clients en voyage d'affaires** répondent-ils autrement que ceux qui voyagent pour leurs loisirs ? 53 % contre 41 % : douze points d'écart. Est-ce une vraie différence, ou le hasard du tirage ?

Votre pronostic, avant de lire la suite. Si la chaîne tirait au sort 800 autres clients, retrouverait-elle 45,5 % ? Entre quelles valeurs pourrait varier sa part : à un point près, à cinq points près, à dix points près ? Notez votre réponse : la section 2.2 la met à l'épreuve.

2. ESTIMER, PUIS TESTER

2.1 Population, échantillon, paramètre, estimation

- **La population** : tous les clients de la chaîne cette année.
- **Le paramètre** : la part p de ceux qui jugent acceptable un prix variable. Elle est fixe, mais inconnue.
- **L'échantillon** : les 800 clients tirés au sort.
- **L'estimation** : la fréquence observée dans l'échantillon, f = 364 / 800 = 0,455. Notée $\hat{p}$, elle se lit « p chapeau ».

Un autre tirage de 800 clients donnerait une autre fréquence : f **fluctue** d'un échantillon à l'autre. Le chapitre 4 dit comment : f suit à peu près $N(p ; \sqrt{(p(1-p)/n)})$. Si la vraie part était p = 0,45, l'écart-type de f vaudrait $\sqrt{(0,45 \times 0,55 / 800)} \approx 0,0176$, et 95 % des échantillons de 800 clients donneraient une fréquence entre $0,45 - 1,96 \times 0,0176 \approx 0,416$ et 0,484.

Le problème est renversé : on ne connaît pas p, on connaît f. Mais si f tombe 95 fois sur 100 à moins de 1,96 écart-type de p, alors p est, 95 fois sur 100, à moins de 1,96 écart-type de f. C'est l'idée de l'intervalle de confiance. Le chapitre 4 allait de p à f, de la population à l'échantillon ; l'estimation fait le chemin inverse, de l'échantillon à la population.

2.2 L'intervalle de confiance à 95 % d'une proportion

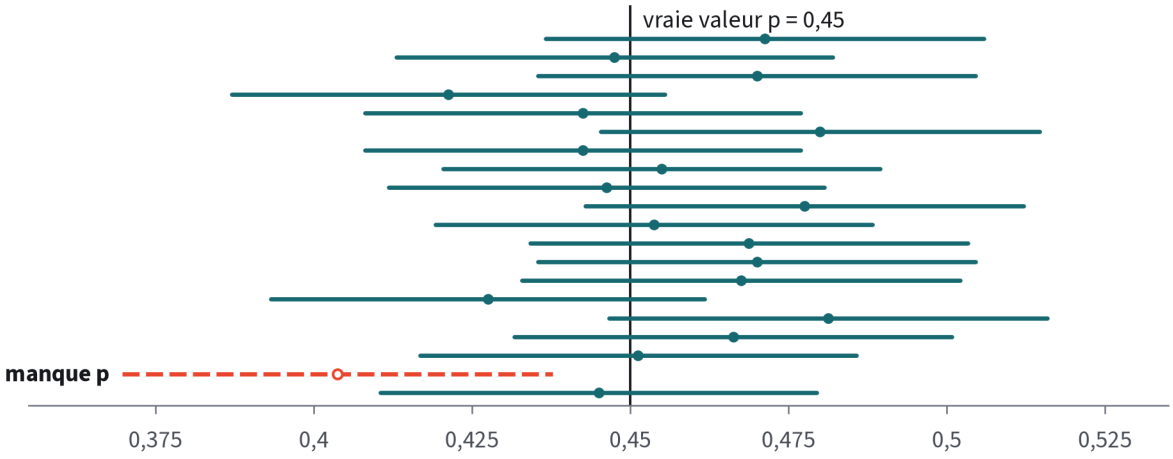
On ne connaît pas p : dans l'écart-type √(p(1 − p) / n), on le remplace par f. L'intervalle de confiance à 95 % de p est :

$$\left[f - 1{,}96\sqrt{\frac{f(1-f)}{n}} \;\; ; \;\; f + 1{,}96\sqrt{\frac{f(1-f)}{n}} \right]$$

Les conditions : un échantillon tiré au hasard dans la population, des observations indépendantes, n ≥ 30, nf ≥ 5 et n(1 − f) ≥ 5.

Pour la chaîne : f = 0,455 et n = 800. √(0,455 × 0,545 / 800) ≈ 0,0176 ; 1,96 × 0,0176 ≈ 0,035 ; l'intervalle va de 0,455 − 0,035 ≈ 0,420 à 0,455 + 0,035 ≈ 0,490. En une phrase : « Entre 42 % et 49 % des clients de la chaîne jugent acceptable un prix qui varie selon la demande, au niveau de confiance de 95 %. » Votre pronostic : à trois ou quatre points près.

Ce qu'il veut dire. La méthode, tirer un échantillon au hasard puis calculer f ± 1,96 √(f(1 − f) / n), produit un intervalle qui contient la vraie valeur p environ 95 fois sur 100. Ci-dessous, vingt échantillons de 800 clients, tirés par simulation dans une population où p = 0,45 : dix-neuf intervalles contiennent p, un le manque. Sur 10 000 échantillons tirés de la même façon, 94,9 % des intervalles contiennent p.



Proportion : chaque trait est un intervalle de confiance à 95 %, le point est f

Ce qu'il ne veut pas dire.

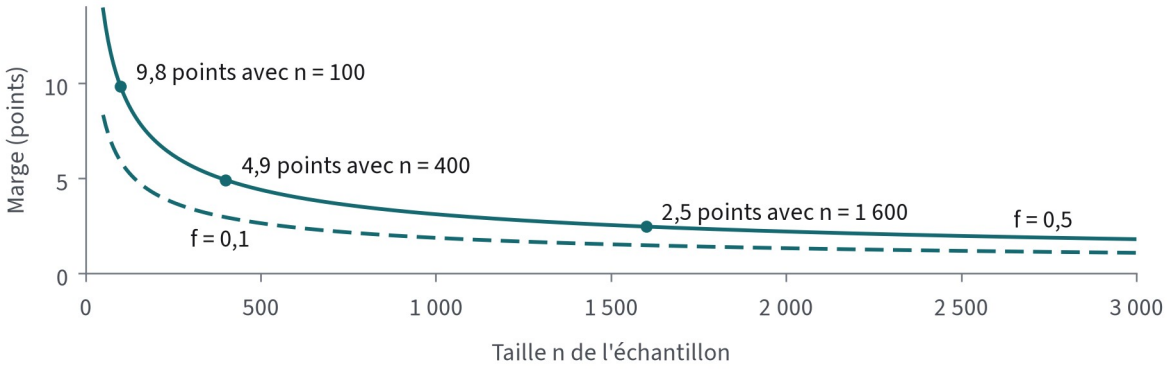
- Il ne dit pas que p a 95 % de chances d'être entre 0,420 et 0,490 : p est fixe, il est dans cet intervalle ou il n'y est pas. Les 95 % portent sur la méthode, qui réussit 95 fois sur 100.
- Il ne dit pas que 95 % des clients sont dans l'intervalle : il porte sur une part, pas sur des individus.
- Il ne mesure que la fluctuation due au tirage au sort. Un échantillon qui n'a pas été tiré au hasard, ou une question mal comprise, faussent le résultat sans que l'intervalle s'élargisse.

2.3 La marge d'erreur et la taille de l'échantillon

La demi-largeur de l'intervalle est la **marge d'erreur** :

$$\text{marge} = 1{,}96\sqrt{\frac{f(1-f)}{n}}$$

Elle diminue comme 1 / √n : **pour diviser la marge par deux, il faut quatre fois plus d'observations.** Pour f = 0,5, elle vaut 9,8 points avec 100 personnes, 4,9 avec 400, 2,5 avec 1 600, 1,0 avec 10 000.



La marge est la plus grande pour f = 0,5. D'où une règle de prudence : avant l'enquête, f est inconnue, et on la remplace par 0,5. Pour une marge de 3 points, il faut n tel que $1{,}96 \times \sqrt{(0{,}5 \times 0{,}5 / n)} = 0{,}03$, soit $n = (1{,}96 / 0{,}03)^2 \times 0{,}25 \approx 1\,067{,}1$: 1 068 personnes.

Pour la chaîne, la marge vaut 3,5 points avec 800 clients. La ramener à 1,7 point demanderait 3 200 clients.

2.4 Le test de deux proportions

La seconde question compare deux groupes : 53 % des 300 clients en voyage d'affaires, 41 % des 500 en voyage de loisirs. Notons p_1 et p_2 les vraies parts, $f_1 = 0{,}53$ et $f_2 = 0{,}41$ les fréquences observées, $n_1 = 300$ et $n_2 = 500$.

Les deux hypothèses. L'hypothèse nulle, H_0 : $p_1 = p_2$, les deux groupes répondent pareil, et l'écart observé ne vient que du hasard du tirage. L'hypothèse alternative, H_1 : $p_1 \neq p_2$. Le test raisonne par l'absurde : il suppose H_0 vraie, et regarde si l'écart observé serait alors rare.

La statistique du test. Si H_0 est vraie, les deux groupes ont une même proportion, qu'on estime en les réunissant : $f = (159 + 205) / (300 + 500) = 0{,}455$. L'écart $f_1 - f_2$ fluctue alors autour de 0, avec un écart-type que donne le dénominateur ci-dessous. La statistique z mesure l'écart observé en écarts-types :

$$z = \frac{f_1 - f_2}{\sqrt{f(1-f)\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

Ici, $\sqrt{(0{,}455 \times 0{,}545 \times (1/300 + 1/500))} \approx 0{,}0364$, et $z \approx (0{,}53 - 0{,}41) / 0{,}0364 \approx 3{,}30$. Si H_0 est vraie, z suit à peu près la loi N(0 ; 1).

La p-valeur (*p-value* en anglais) est la probabilité, si H_0 était vraie, d'obtenir un écart au moins aussi grand que l'écart observé, dans un sens ou dans l'autre : $P(Z \leq -|z|) + P(Z \geq |z|) = 2 \times P(Z \geq |z|)$. Ici, `2 × norm.sf(3.30)` ≈ 0,001. Si les deux groupes répondaient pareil, un écart de douze points ou plus ne se produirait qu'environ une fois sur mille.

Le seuil de 5 %. On le fixe avant le test. Si la p-valeur est inférieure à 5 %, on rejette H_0 : la différence est dite **significative** au seuil de 5 %. Sinon, on ne rejette pas H_0. Au seuil de 5 %, cela revient à $|z| > 1{,}96$. Le seuil est le risque qu'on accepte de conclure à une différence quand H_0 est vraie.

La conclusion, en une phrase. « Au seuil de 5 %, la part des clients qui jugent acceptable un prix variable diffère entre voyages d'affaires et de loisirs : 53 % contre 41 %, p-valeur ≈ 0,001. »

Les conditions : deux échantillons indépendants, tirés au hasard ; $n_1 f$, $n_1(1 - f)$, $n_2 f$ et $n_2(1 - f)$ au moins égaux à 5. Ici : 136,5 ; 163,5 ; 227,5 ; 272,5.

En Python :

```
from math import sqrt
from scipy.stats import norm
x1, n1, x2, n2 = 159, 300, 205, 500
f1, f2, f = x1 / n1, x2 / n2, (x1 + x2) / (n1 + n2)
z = (f1 - f2) / sqrt(f * (1 - f) * (1 / n1 + 1 / n2))
p_valeur = 2 * norm.sf(abs(z))
```

z vaut environ 3,30, et `p_valeur` environ 0,001.

2.5 « Non significatif » ne veut pas dire « aucun effet »

Une plateforme de cours en ligne se demande si un tutoriel d'accueil retient ses nouveaux inscrits. Elle en tire 400 au sort : 200 voient le tutoriel, 200 ne le voient pas. Trente jours plus tard, 60 des premiers, 30 %, et 48 des seconds, 24 %, suivent encore un cours. Chiffres fictifs. Le test donne z ≈ 1,35 et une p-valeur d'environ 0,18 : la différence n'est pas significative au seuil de 5 %.

Conclure « le tutoriel n'a aucun effet » serait une erreur. Le test dit seulement que ces données ne suffisent pas à écarter l'hypothèse d'égalité. **Une absence de preuve n'est pas une preuve d'absence.**

Ce qu'un résultat non significatif permet de dire. « Avec 200 inscrits par groupe, on n'a pas mis en évidence d'effet du tutoriel au seuil de 5 %. » Pour dire ce que les données n'excluent pas, on calcule l'**intervalle de confiance de la différence** :

$$(f_1 - f_2) \pm 1{,}96\sqrt{\frac{f_1(1-f_1)}{n_1} + \frac{f_2(1-f_2)}{n_2}}$$

Ici, 0,06 ± 1,96 × √(0,30 × 0,70 / 200 + 0,24 × 0,76 / 200) ≈ 0,06 ± 0,087 : de −2,7 à +14,7 points. Les données sont compatibles avec un tutoriel sans effet, avec un tutoriel un peu nuisible, et avec un tutoriel qui retient près de quinze inscrits de plus sur cent. Elles ne permettent pas de conclure : l'échantillon est trop petit.

Avec plus de données. Le même écart de 6 points, 30 % contre 24 %, avec 2 000 inscrits par groupe : z ≈ 4,27, p-valeur inférieure à 0,001, et un intervalle de la différence de 3,3 à 8,7 points. Le même écart devient significatif. Qu'un résultat soit significatif dépend de l'effet, mais aussi de la taille de l'échantillon.

L'intervalle de la différence se calcule avec f_1 et f_2 séparément ; la statistique z, avec la fréquence commune f, puisqu'elle suppose H_0 vraie. Leurs conclusions concordent en général : l'intervalle contient 0 quand le test n'est pas significatif.

2.6 Pourquoi tirer au sort

Une application de sport constate : parmi ses 1 000 utilisateurs qui ont activé les notifications, 450, soit 45 %, sont encore actifs au bout de trois mois ; parmi les 2 000 autres, 400, soit 20 %. Chiffres fictifs. Le test de deux proportions est très significatif. Les notifications retiennent-elles les utilisateurs ?

Ces chiffres ne le prouvent pas. Ceux qui activent les notifications ne sont pas pris au hasard : ce sont souvent les plus motivés, qui seraient restés de toute façon. La motivation est une **cause commune** : elle pousse à activer les notifications, et elle pousse à rester. Elle fausse la comparaison : c'est la **confusion**. Le test dit que les deux groupes diffèrent ; il ne dit pas pourquoi.

Le tirage au sort coupe ce lien. Si l'application décide au hasard qui reçoit les notifications, les plus motivés et les autres se répartissent à peu près également entre les deux groupes, comme toutes les

autres causes possibles, connues ou non. Une différence significative peut alors être attribuée aux notifications. C'est le principe du **test A/B** : deux versions, des utilisateurs répartis au hasard entre elles, une proportion mesurée dans chaque groupe.

Le calcul du test est le même dans les deux cas ; c'est l'interprétation qui change. Sans tirage au sort, le test établit une différence entre deux groupes ; avec le tirage au sort, il établit un effet.

2.7 Retour à la chaîne d'hôtels

1. **La part de tous ses clients** qui jugent acceptable un prix variable : entre 42 % et 49 %, au niveau de confiance de 95 %. Moins d'un client sur deux, sans doute ; mais la chaîne ne connaît cette part qu'à 3,5 points près.
2. **Affaires et loisirs** : 53 % contre 41 %, une différence significative au seuil de 5 %, p-valeur ≈ 0,001. L'intervalle de confiance de la différence va de 4,9 à 19,1 points : l'écart est significatif, mais sa taille reste mal connue.

Les deux groupes n'ont pas été formés par tirage au sort : le test dit qu'ils répondent différemment, il ne dit pas pourquoi.

À retenir

Un paramètre p est fixe et inconnu ; la fréquence f d'un échantillon l'estime, et fluctue d'un échantillon à l'autre.

L'intervalle de confiance à 95 % : $f \pm 1{,}96\sqrt{f(1-f)/n}$, pour un échantillon tiré au hasard, avec $n \geq 30$, $nf \geq 5$ et $n(1-f) \geq 5$. La méthode capture la vraie valeur environ 95 fois sur 100.

La marge d'erreur diminue comme $1/\sqrt{n}$: la diviser par deux demande quatre fois plus d'observations.

Le test de deux proportions : $H_0 : p_1 = p_2$; la statistique z ; la p-valeur, $2 \times P(Z \geq |z|)$. Si elle est inférieure à 5 %, la différence est significative au seuil de 5 %.

« Non significatif » ne veut pas dire « aucun effet » : l'intervalle de confiance de la différence dit ce que les données n'excluent pas.

Sans tirage au sort, une cause commune peut fausser la comparaison : la confusion. Le tirage au sort permet de conclure à un effet.

3. CÔTÉ IA ET DATA

3.1 L'intervalle de confiance du score d'un modèle

Un modèle répond juste à 412 des 500 questions d'un jeu de test tirées au hasard. Son score est $f = 412 / 500 = 0{,}824$, et son intervalle de confiance à 95 % : $0{,}824 \pm 1{,}96 \times \sqrt{0{,}824 \times 0{,}176 / 500} \approx 0{,}824 \pm 0{,}033$, de 0,791 à 0,857. Chiffres fictifs. Un score annoncé sans intervalle cache cette incertitude : sur 500 questions, la marge est de 3,3 points, et un écart de deux points avec un autre modèle peut venir du seul choix des questions.

3.2 La calibration

Un modèle qui accompagne chaque réponse d'une probabilité est **bien calibré** si ses probabilités disent vrai : parmi les réponses qu'il donne avec 90 % de confiance, environ 90 % sont justes. Cela se vérifie par une estimation. On tire au hasard 800 réponses données avec 90 % de confiance, et on les vérifie une à une : 680 sont justes. f = 0,85, et l'intervalle de confiance à 95 % va de 0,825 à 0,875. Chiffres fictifs. 0,90 est hors de l'intervalle : à ce niveau de confiance, le modèle est trop sûr de lui. Une vérification complète refait ce calcul pour chaque niveau de confiance annoncé.

En 2017, C. Guo, G. Pleiss, Y. Sun et K. Q. Weinberger montrent que les réseaux de neurones récents sont moins bien calibrés que ceux d'une décennie plus tôt. Sur un même jeu d'images, la confiance moyenne d'un réseau profond récent dépasse nettement son taux de bonnes réponses, quand celle d'un réseau plus ancien et plus petit lui correspond : le réseau récent est trop sûr de lui.

Jev, présenté par TypeSafe AI le 15 septembre 2026, répond par des décisions typées assorties de probabilités, sans produire de texte. Selon son fabricant, une méthode d'entraînement nommée RLCD lui donne des probabilités calibrées. C'est une affirmation du fabricant. Il ne publie pas de vérification niveau par niveau, comme celle ci-dessus ; et sa définition de « calibré », une confiance plus haute va avec plus de bonnes réponses, est plus faible que celle de cette section. Des mesures indépendantes commencent à paraître ; elles ne sont pas encore relues par des pairs.

Sources : C. Guo, G. Pleiss, Y. Sun, K. Q. Weinberger, « On Calibration of Modern Neural Networks », ICML 2017, PMLR, vol. 70, p. 1321–1330, proceedings.mlr.press/v70/guo17a.html ; D. Almeida, « Introducing System One Models & Jev », blog de TypeSafe AI, 15 septembre 2026, typesafe.ai/blog/introducing-system-one-models-and-jev.

3.3 Comparer deux versions d'un modèle

Une entreprise propose à ses développeurs un assistant de programmation. Sa nouvelle version, B, fait-elle mieux que la version actuelle, A ? Elle tire au sort 10 000 utilisateurs : 5 000 gardent A, 5 000 reçoivent B. Elle mesure la part de ceux qui se servent encore de l'assistant au bout d'un mois : 1 150, soit 23,0 %, avec A ; 1 260, soit 25,2 %, avec B. Chiffres fictifs.

Le test donne z ≈ 2,57 et une p-valeur d'environ 0,010 : B fait mieux, au seuil de 5 %. L'intervalle de confiance de la différence va de 0,5 à 3,9 points. Le tirage au sort permet d'attribuer la différence à la version, et non aux utilisateurs : si B avait été proposée à des volontaires, les plus assidus l'auraient choisie, et la comparaison serait faussée. Reste à décider si un gain de 0,5 à 3,9 points vaut le coût de la nouvelle version : c'est une autre question que la significativité.

4. AILLEURS AUSSI

La marge d'erreur d'un sondage. Un sondage interroge 1 000 personnes tirées au hasard ; 52 % déclarent vouloir voter pour une candidate. La marge vaut 1,96 × √(0,52 × 0,48 / 1 000) ≈ 3,1 points : l'intervalle va de 48,9 % à 55,1 %. Chiffres fictifs. La candidate n'est pas assurée d'être majoritaire. C'est la « marge d'erreur de 3 points » des sondages de 1 000 personnes ; elle suppose un tirage au hasard.

En médecine, l'absence de preuve n'est pas la preuve de l'absence. Un essai clinique qui ne trouve pas de différence significative entre deux traitements est souvent dit « négatif », comme s'il prouvait qu'ils se valent. En 1995, dans le *BMJ*, les statisticiens D. G. Altman et J. M. Bland rappellent qu'un tel essai montre

seulement une absence de preuve, et que beaucoup d'essais sont trop petits pour repérer même un effet important. Leur exemple : un essai de 100 patients a conclu que deux traitements se valaient, alors que le calcul en demandait 1 800, et que son intervalle de confiance n'excluait pas un écart de 20 points. Source : D. G. Altman, J. M. Bland, « Absence of evidence is not evidence of absence », *BMJ*, vol. 311, 1995, p. 485, bmj.com/content/311/7003/485.

5. MÉTHODES ET PIÈGES

Une méthode en quatre temps pour un test

1. **Poser les hypothèses** et le seuil, avant de regarder les résultats : $H_0 : p_1 = p_2$; $H_1 : p_1 \neq p_2$; seuil de 5 %.
2. **Vérifier les conditions** : échantillons tirés au hasard, indépendants, effectifs suffisants.
3. **Calculer** f, z et la p-valeur, puis l'intervalle de confiance de la différence.
4. **Conclure en une phrase**, avec les deux fréquences, la p-valeur et l'intervalle : significatif ou non, et ce que les données n'excluent pas.

Les pièges

- **Lire un intervalle de confiance comme une probabilité sur la vraie valeur.** « p a 95 % de chances d'être dans [0,420 ; 0,490] » est faux : les 95 % sont ceux de la méthode.
- **Confondre la marge d'une proportion et celle d'une différence.** La chaîne connaît la part des voyages d'affaires à 5,6 points près, celle des voyages de loisirs à 4,3 points près ; leur différence, à 7,1 points près seulement. La marge de la différence additionne les deux variances sous la racine : elle dépasse chacune des deux marges.
- **Conclure « aucun effet » d'un test non significatif.** Il faut dire « pas d'effet mis en évidence », et donner l'intervalle de la différence.
- **Prendre « significatif » pour « important ».** Avec 200 000 personnes par groupe, 30,0 % contre 29,6 % est significatif, p-valeur ≈ 0,006 ; l'écart, 0,4 point, est peut-être sans intérêt. Regardez toujours la taille de l'écart et son intervalle.
- **Regarder les données en cours de route, et s'arrêter dès que c'est significatif.** Chaque coup d'œil donne au hasard une chance de plus de passer sous 5 % : le risque de conclure à tort dépasse alors largement 5 %. Fixez la taille de l'échantillon avant de commencer.
- **Oublier les conditions.** Tirage au hasard, indépendance, au moins 5 succès et 5 échecs attendus dans chaque groupe.
- **Comparer sans tirage au sort.** Deux groupes formés d'eux-mêmes peuvent différer par une cause commune : la différence n'est pas un effet.

6. EXERCICES

Huit exercices, sur trois niveaux : appliquer (exercices 1 et 2), interpréter (exercices 3 et 4), résoudre un problème en contexte (exercices 5 à 8). Les chiffres sont fictifs. Donnez les proportions en décimal arrondi au millième, les écarts en points. Les corrigés, détaillés pas à pas, sont dans le fascicule « MTH101 · Chapitre 5 · Corrigés », aux mêmes numéros : cherchez d'abord, lisez ensuite.

Exercice 1 · La bibliothèque

Une bibliothèque tire au sort 250 de ses inscrits : 90 utilisent son service de réservation en ligne.

1. Donnez l'estimation de la part p des inscrits qui utilisent ce service.
2. Les conditions de l'intervalle de confiance sont-elles remplies ?
3. Calculez l'intervalle de confiance à 95 % de p, et rédigez-le en une phrase.

Exercice 2 · Combien interroger ?

Une mairie veut estimer la part des habitants qui souhaitent une rue piétonne, par une enquête auprès d'habitants tirés au sort.

1. Sans rien savoir de cette part, combien interroger d'habitants pour une marge de 5 points ?
2. Et pour une marge de 2,5 points ? Comparez.
3. Chaque entretien coûte 8 €. Que coûte chacune des deux enquêtes ?

Exercice 3 · Le casque à vélo

Sur 400 cyclistes tirés au sort dans une ville, 232 portent un casque. On calcule l'intervalle de confiance à 95 % de la part des cyclistes casqués : de 0,532 à 0,628. Vrai ou faux ? Justifiez.

1. « La vraie part des cyclistes casqués a 95 % de chances d'être entre 53,2 % et 62,8 %. »
2. « 95 % des cyclistes portent un casque entre 53,2 % et 62,8 % du temps. »
3. « Un autre échantillon de 400 cyclistes donnerait un autre intervalle. »
4. « Avec 1 600 cyclistes, l'intervalle serait à peu près deux fois plus étroit. »
5. « Au niveau de confiance de 95 %, la part des cyclistes casqués dépasse 50 %. »
6. « L'intervalle tient compte de toutes les erreurs possibles de l'enquête. »

Exercice 4 · Trois tests

Une boutique en ligne a mené trois tests A/B : dans chacun, des clients tirés au sort voient l'ancienne ou la nouvelle version, autant pour chacune. Elle mesure la part des visites qui se terminent par un achat.

Test	Clients	Nouvelle	Ancienne	p-valeur	Intervalle de l'écart
1. Page de livraison	2 × 50 000	10,6 %	10,2 %	0,038	de 0,02 à 0,78 point
2. Photos des produits	2 × 120	25,0 %	17,5 %	0,156	de −2,8 à 17,8 points
3. Retours gratuits	2 × 3 000	12,0 %	9,0 %	0,0002	de 1,5 à 4,5 points

1. Lesquels de ces tests sont significatifs au seuil de 5 % ?
2. Pour chacun, écrivez la conclusion en une phrase.
3. La boutique veut étendre une seule version à tous ses clients. Laquelle, et pourquoi ?
4. Que proposez-vous pour le test 2 ?

Exercice 5 · Le rappel par SMS

Une banque en ligne tire au sort 2 400 clients qui ont un prêt : 1 200 reçoivent un SMS de rappel trois jours avant chaque échéance, les 1 200 autres non. Sur un trimestre, 66 clients du premier groupe et 96 du second paient au moins une échéance après la date prévue. Répondez avec Python.

1. Calculez les deux fréquences.
2. Posez les hypothèses, puis calculez z et la p-valeur.

3. Concluez au seuil de 5 %.
4. Calculez l'intervalle de confiance de la différence. Que dit-il ?
5. Peut-on dire que le SMS est la cause de la différence ? Pourquoi ?

Exercice 6 · L'essai gratuit

Une plateforme de livres audio tire au sort 300 nouveaux utilisateurs : 150 reçoivent un essai gratuit de 14 jours, 150 un essai de 30 jours. À la fin de l'essai, 33 du premier groupe et 42 du second s'abonnent.

1. Calculez les deux fréquences, z et la p-valeur. La différence est-elle significative au seuil de 5 % ?
2. Le responsable conclut : « La durée de l'essai n'a aucun effet. » Que lui répondez-vous ?
3. Calculez l'intervalle de confiance de la différence, et dites ce que les données n'excluent pas.
4. Pour connaître la différence à 3 points près, avec des parts voisines de 25 %, combien faudrait-il d'utilisateurs par groupe ? Utilisez une marge de $1{,}96 \times \sqrt{(0{,}25 \times 0{,}75 / n + 0{,}25 \times 0{,}75 / n)}$.

Exercice 7 · Le tutorat

Dans une université, 120 étudiants de première année ont suivi des séances de tutorat facultatives : 90 ont réussi leurs examens du premier semestre. Parmi les 280 autres, 168 ont réussi.

1. Calculez les deux taux de réussite. La différence est-elle significative au seuil de 5 % ?
2. « Le tutorat fait réussir », dit l'université. Votre avis ? Deux causes communes possibles ?
3. Proposez un protocole qui permettrait de mesurer l'effet du tutorat.
4. Avec ce protocole, que permettrait de dire un résultat significatif ?

Exercice 8 · Un modèle trop sûr de lui ?

Un modèle de tri de photos annonce la probabilité qu'une photo montre un animal. On vérifie à la main des photos tirées au hasard : parmi 400 photos annoncées à 80 %, 296 montrent un animal ; parmi 200 annoncées à 50 %, 106.

1. Pour chaque groupe, calculez la fréquence et son intervalle à 95 %.
2. Le modèle est-il bien calibré pour les photos annoncées à 80 % ? À 50 % ?
3. Rédigez pour l'équipe qui utilise le modèle un message de trois lignes.

7. POUR ALLER PLUS LOIN

Ressource	Ce que vous y trouverez
OpenIntro Statistics, 4e édition, D. Diez, M. Çetinkaya-Rundel, C. Barr : openintro.org/book/os, en anglais	L'intervalle et le test pour une proportion (chapitre 5), puis pour deux proportions (section 6.2), avec de nombreux exercices.
Seeing Theory, université Brown, en anglais : seeing-theory.brown.edu/frequentist-inference	La section interactive « Confidence Interval ».
Khan Academy, en français, « Statistique et probabilités » : fr.khanacademy.org/math/statistics-probability	« Intervalle de confiance » et « Comparaison de deux proportions », en vidéos et exercices corrigés.
D. G. Altman, J. M. Bland, « Absence of evidence is not evidence of absence », *BMJ*, 1995, en anglais	Une page sur l'erreur de la section 2.5, avec des exemples d'essais cliniques.