MTH101 · Chapitre 6

De la donnée à la décision : recommander sous incertitude

Adrien Chiodo

Octobre 2026

Comment travailler ce chapitre. Il clôt le cours avant les soutenances : un résultat chiffré ne suffit pas au client, il lui faut une décision, et une recommandation qu'il puisse suivre. Il se suffit à lui-même ; ce qu'il prend aux chapitres précédents est rappelé sur place.

Ce qu'il suppose. Le chapitre 3 : espérance, écart-type. Le chapitre 5 : intervalle de confiance d'une différence, test de deux proportions, tirage au sort.

Le temps. Comptez environ trois heures : une heure et demie pour les sections 1 et 2, crayon en main ; une demi-heure pour les sections 3 à 5 ; une heure pour les exercices, dont deux à rédiger.

Les exercices sont corrigés dans un fascicule à part, « MTH101 · Chapitre 6 · Corrigés », aux mêmes numéros. Cherchez d'abord : un corrigé lu trop tôt n'apprend presque rien.

De l'aide. Une notion qui résiste : le kit tuteur du site du cours, ad-c.github.io/mth101, qui fait d'un assistant IA un tuteur. Une question qui reste : l'intervenant, adrien.chiodo@ecole-89.com.

Les chiffres de ce chapitre sont fictifs, sauf mention d'une source.

1. LA NOUVELLE PAGE DE RÉSERVATION

Une chaîne d'hôtels, cliente de l'agence, a redessiné la page de réservation de son site : moins de champs à remplir, les photos des chambres en tête. Avant de la mettre en ligne pour tous, elle l'a testée une semaine, par un test A/B. Les 20 000 internautes arrivés sur la page ont été répartis par tirage au sort : 10 000 ont vu l'ancienne page, 10 000 la nouvelle. On compte ceux qui réservent dans la semaine.

	Internautes	Réservations	Part
Ancienne page	10 000	400	4,0 %
Nouvelle page	10 000	480	4,8 %

Chiffres fictifs. Avant le test, la direction a fixé sa règle : la nouvelle page ne sera adoptée que si elle fait réserver au moins 0,5 point de plus ; en dessous, le gain ne paie pas sa mise en place sur les douze sites de la chaîne.

L'analyste de l'agence a fait les calculs du chapitre 5. La différence vaut 0,8 point ; elle est significative au seuil de 5 %, p-valeur ≈ 0,006 ; son intervalle de confiance à 95 % va de 0,2 à 1,4 point. La nouvelle page fait un peu mieux, mais l'intervalle est large. La direction demande : « Faut-il l'adopter pour tout le site ? »

Votre pronostic, avant de lire la suite. Que répondez-vous : oui, puisque 0,8 dépasse 0,5 et que le test est significatif ; non ; ou pas encore ? Notez votre réponse : la section 2.8 la met à l'épreuve.

2. DE LA DONNÉE À LA DÉCISION

2.1 De la question du client aux options

Une question de client cache une décision. « Faut-il adopter la nouvelle page ? » demande de choisir entre des options : au moins agir ou ne pas agir, souvent une troisième, en savoir plus avant de choisir. Avant de regarder les résultats, on écrit ces options, et pour chacune ce qui ferait pencher pour elle : une condition sur ce qu'on ne connaît pas, ici la vraie différence entre les deux pages.

Option	Ce qui ferait pencher pour elle
Adopter la nouvelle page	Une vraie différence d'au moins 0,5 point
Garder l'ancienne	Une vraie différence de moins de 0,5 point, ou négative
Tester encore	Des données qui ne permettent pas de trancher, et une décision qui peut attendre

Ces conditions forment la **règle de décision** : quel résultat fera recommander quoi. Écrite d'avance, elle empêche d'ajuster la conclusion au résultat. Le seuil de 0,5 point vient des conséquences : c'est le plus petit gain qui paie le changement (section 2.5).

2.2 L'espérance d'une option, et sa dispersion

Quand les conséquences d'une option sont incertaines, on les compare par leur **espérance** : chaque conséquence pondérée par sa probabilité, comme au chapitre 3.

Une étudiante va en cours en voiture. Par la rocade, le trajet dure 20 minutes trois jours sur quatre, et 60 minutes les jours de bouchon. Par le centre-ville, il dure 32 minutes, presque sans variation. Chiffres fictifs. Notons T la durée par la rocade :

- $E(T) = 20 \times 0{,}75 + 60 \times 0{,}25 = 30$ minutes, contre 32 par le centre ;
- $E(T^2) = 400 \times 0{,}75 + 3\,600 \times 0{,}25 = 1\,200$, d'où $V(T) = 1\,200 - 30^2 = 300$ et $\sigma(T) = \sqrt{300} \approx 17$ minutes, contre presque 0 par le centre.

Pour les trajets de tous les jours, la rocade l'emporte : 2 minutes de moins par trajet en moyenne, 400 minutes sur 200 trajets ; les jours de bouchon sont compensés par les autres. Mais le jour d'un examen, partie 40 minutes avant le début, l'étudiante arrive trop tard une fois sur quatre par la rocade, et presque jamais par le centre.

La dispersion compte aussi. L'espérance suffit quand la décision se répète souvent et que chaque mauvaise issue reste supportable : sur un grand nombre de cas, les écarts se compensent (chapitre 3, section 2.8). Quand la décision ne se prend qu'une fois, ou qu'une mauvaise issue coûterait bien plus que les autres, on regarde aussi l'écart-type, et la probabilité de la mauvaise issue.

2.3 Quand les deux erreurs ne coûtent pas autant

Beaucoup de décisions se prennent par oui ou non, au vu d'une probabilité : classer un message comme spam, demander un examen de plus. On peut se tromper de deux façons :

- un **faux positif** : agir, alors que l'événement n'a pas lieu ;
- un **faux négatif** : ne pas agir, alors qu'il a lieu.

Notons P la probabilité de l'événement, c_{FP} le coût d'un faux positif et c_{FN} celui d'un faux négatif. Agir coûte en moyenne $(1 - P) \times c_{FP}$; ne pas agir, $P \times c_{FN}$. Agir vaut mieux quand $P \times c_{FN}$ dépasse $(1 - P) \times c_{FP}$, c'est-à-dire quand :

$$\text{agir si} \quad P > \frac{c_{FP}}{c_{FP} + c_{FN}}$$

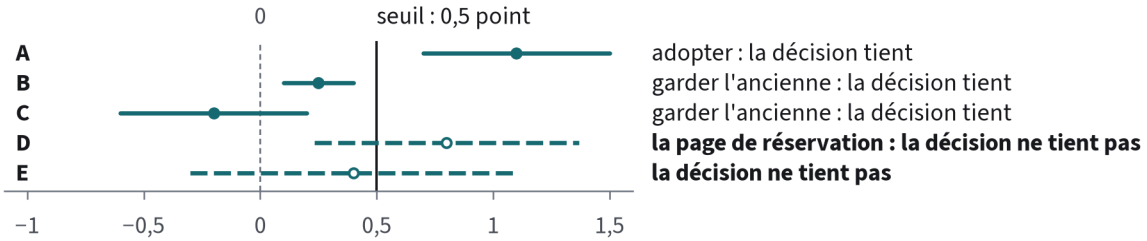
Si les deux erreurs coûtent autant, le seuil vaut 0,5 : on agit quand l'événement est plus probable que non. Si un faux négatif coûte 9 fois plus qu'un faux positif, le seuil tombe à 1 / (1 + 9) = 0,1 : on agit dès 10 % de chances, en sachant qu'on agira souvent pour rien, mais à petit coût. Si c'est le faux positif qui coûte 9 fois plus, le seuil monte à 0,9. **Le seuil d'une décision vient des coûts des deux erreurs, pas de la seule probabilité.** Le filtre anti-spam (section 3.2) et le dépistage (section 4) le placent à deux extrêmes.

Déplacer le seuil échange une erreur contre l'autre : le monter réduit les faux positifs et augmente les faux négatifs. Aucun seuil ne supprime les deux ; le bon seuil rend leur coût total le plus petit possible.

2.4 Décider avec l'intervalle, pas avec le seul point

Retour à la page de réservation. L'estimation, 0,8 point, dépasse le seuil de 0,5 : sur ce seul point, on adopterait. Mais la vraie différence est quelque part entre 0,2 et 1,4 point, au niveau de confiance de 95 %. Si elle vaut 1,2 point, adopter est le bon choix ; si elle vaut 0,3 point, c'est une erreur.

La question à poser : la décision tient-elle de la borne basse à la borne haute ? On prend la décision pour chaque valeur de l'intervalle. Si c'est partout la même, les données suffisent. Sinon, elles ne tranchent pas, aussi nette que paraisse l'estimation.



Différence, en points : chaque trait est un intervalle de confiance à 95 %, le point est l'estimation

- **A** : tout l'intervalle est au-dessus du seuil ; adopter, la décision tient.
- **B** : au-dessus de 0, mais sous le seuil ; le gain est réel, trop petit pour payer le changement : garder l'ancienne, la décision tient.
- **C** : l'intervalle contient 0, mais il est tout entier sous le seuil ; garder l'ancienne, la décision tient aussi, bien que le test ne soit pas significatif.
- **D**, la page de réservation, et **E** : à cheval sur le seuil ; la décision change à l'intérieur de l'intervalle.

Quand l'intervalle est à cheval sur le seuil, deux voies. En savoir plus, par un nouveau test, de taille fixée d'avance pour resserrer l'intervalle ; non pas le premier, prolongé jusqu'à ce qu'il convienne (chapitre 5, section 5). Ou décider quand même, en choisissant l'option dont l'erreur coûte le moins (section 2.3), et en le disant.

2.5 Significatif ou important

Le test du chapitre 5 répond à une question : la différence peut-elle venir du seul hasard du tirage ? La décision en pose une autre : la différence est-elle assez grande pour compter ? Le **seuil d'importance**

pratique y répond : le plus petit effet qui changerait la décision. Il se tire des conséquences, pas des données : pour la chaîne, le gain qui paie la mise en place de la nouvelle page sur ses douze sites.

Les deux réponses peuvent diverger. Dans la figure, A est significatif et important ; B, significatif mais sans importance, comme ces écarts minuscules qu'un très grand échantillon rend significatifs (chapitre 5, section 5) ; E n'est pas significatif, et pourrait pourtant être important.

Il se fixe avant de regarder les données. Après, la tentation est de le placer là où le résultat arrange : à 0,2 point, pour que tout l'intervalle de la chaîne le dépasse. Un seuil choisi après coup ne protège plus de rien, comme un test arrêté dès qu'il devient significatif. Il s'écrit dans la règle de décision.

Deux seuils, deux rôles. Le seuil de 5 % du test règle le risque de conclure à une différence qui n'existe pas ; le seuil d'importance pratique dit à partir de quelle taille la différence compte. Le premier est une convention ; le second se discute avec le client.

2.6 Ce qui autorise à parler de cause

« La nouvelle page fait réserver davantage » est une phrase de cause. Le tirage au sort l'autorise : les internautes ont été répartis au hasard entre les deux pages, si bien que rien d'autre que la page ne distingue les deux groupes, au hasard près, et l'intervalle mesure ce hasard (chapitre 5, section 2.6).

Sans tirage au sort, la même phrase serait abusive. Si la chaîne avait mis la nouvelle page en ligne pour tous en mars, et comparé mars à février, une hausse pourrait venir du printemps, d'une campagne de publicité ou d'un concurrent en difficulté : une comparaison avant–après mêle l'effet de la page à tout ce qui a changé en même temps. Avec tirage au sort, on écrit « fait réserver davantage » ou « a pour effet » ; sans, seulement « va de pair avec » ou « est associé à ».

Le tirage au sort établit un effet sur les internautes testés, pendant la semaine du test. L'étendre à une autre saison ou à un autre public est une hypothèse : elle va dans les limites.

2.7 Écrire la recommandation

La grille commune de l'agence va de la question à la condition de réexamen : question, données, effet estimé, intervalle de confiance, test, importance pratique, limites, recommandation, condition de réexamen. La recommandation en tire l'essentiel, pour un client qui ne lira peut-être qu'elle, en cinq éléments :

1. **la réponse** : l'option recommandée, en une phrase, dans les mots du client ;
2. **la confiance** : l'estimation et son intervalle, dans les unités du client, et ce qui autorise à parler de cause ;
3. **l'importance pratique** : l'effet comparé au seuil fixé d'avance ;
4. **les limites** : ce que les données ne disent pas, et ce que chaque limite change ;
5. **la condition de réexamen** : le fait qui ferait revoir la recommandation.

Un journal en ligne a testé une nouvelle page d'abonnement pendant trois semaines d'octobre : 30 000 lecteurs tirés au sort, 15 000 par page. 3,2 % s'abonnent avec l'ancienne page, 4,2 % avec la nouvelle. Seuil fixé avant le test : 0,5 point. La différence, 1,0 point, a pour intervalle de confiance à 95 % de 0,6 à 1,4 point ; p-valeur inférieure à 0,001. Chiffres fictifs. Deux recommandations, côte à côte :

	Une recommandation faible	Une bonne recommandation
Réponse	« La nouvelle page est meilleure. »	« Adoptez la nouvelle page d'abonnement. »

	Une recommandation faible	Une bonne recommandation
Confiance	« C'est prouvé : p = 0,0000045. »	« Sur 30 000 lecteurs tirés au sort, elle fait s'abonner 4,2 % des lecteurs, contre 3,2 % : 1,0 point de plus, entre 0,6 et 1,4 point au niveau de confiance de 95 %. »
Importance	« Les abonnements augmentent de 31,25 %. »	« Même la borne basse dépasse les 0,5 point fixés avant le test : environ 10 abonnés de plus pour 1 000 lecteurs. »
Limites	Aucune	« Trois semaines d'octobre ; on a compté les abonnements, pas ceux qui durent. »
Réexamen	Aucun	« À revoir si, dans trois mois, les abonnés de la nouvelle page se désabonnent plus souvent. »

La faible ne dit pas quoi faire. Elle annonce une preuve qu'un test ne donne pas, sept décimales sans objet, une hausse relative qui grossit l'effet, 31,25 % pour un point ; ni intervalle, ni seuil, ni limites, ni réexamen.

Les mots de l'incertitude. Ils disent la force de la preuve, ni plus ni moins.

- « Les données montrent que… » : la décision tient de la borne basse à la borne haute.
- « Les données suggèrent que…, sans l'établir » : l'estimation penche d'un côté, l'intervalle déborde de l'autre.
- « Les données ne permettent pas de trancher » : l'intervalle couvre les deux décisions ; dire alors ce qu'il n'exclut pas.
- À éviter : « prouve », « certainement », « sans risque », et « sans effet » pour un test qui n'est pas significatif (chapitre 5).

2.8 Retour à la page de réservation

1. **La règle de décision** : adopter la nouvelle page si la vraie différence atteint 0,5 point.
2. **L'intervalle**, de 0,2 à 1,4 point, est à cheval sur 0,5 : la décision ne tient pas de la borne basse à la borne haute. Le test est significatif, et le tirage au sort permet de dire que la nouvelle page fait réserver davantage ; il n'établit pas qu'elle fasse réserver assez pour payer sa mise en place.
3. **En savoir plus.** Pour connaître la différence à 0,25 point près, il faut n internautes par page, avec $1{,}96 \times \sqrt{(0{,}04 \times 0{,}96 / n + 0{,}048 \times 0{,}952 / n)} = 0{,}0025$, soit $n \approx 51\,690$: environ 52 000 par page, un peu plus d'un mois au rythme du premier test. Si le nouveau test donne encore 0,8 point, son intervalle ira d'environ 0,55 à 1,05 point, tout entier au-dessus du seuil.

La recommandation, en cinq lignes :

> « N'adoptez pas encore la nouvelle page : testez-la de nouveau, sur 52 000 internautes par page, un peu plus d'un mois. Sur 20 000 internautes tirés au sort, elle fait réserver 4,8 % contre 4,0 % : 0,8 point de plus, entre 0,2 et 1,4 point au niveau de confiance de 95 %. Votre seuil, 0,5 point, est dans cet intervalle : le gain est réel, mais peut-être trop petit. Le test n'a duré qu'une semaine, en octobre. Adoptez-la si l'intervalle du nouveau test dépasse tout entier 0,5 point ; sinon, gardez l'ancienne. »

Si l'intervalle du nouveau test contient encore 0,5 point, il sera étroit : la vraie différence sera proche du seuil, et garder l'ancienne page coûtera peu. Votre pronostic : pas encore.

À retenir

Une question de client cache une décision. Avant les données, écrire les options, et pour chacune ce qui ferait pencher pour elle : la règle de décision.

L'espérance compare des options aux conséquences incertaines. La dispersion compte aussi, quand la décision ne se prend qu'une fois ou qu'une mauvaise issue serait grave.

Deux erreurs : le faux positif et le faux négatif. Agir si $P > c_{FP} / (c_{FP} + c_{FN})$: le seuil vient des coûts des deux erreurs.

Décider avec l'intervalle : la décision tient-elle de la borne basse à la borne haute ? Sinon, en savoir plus par un nouveau test, ou choisir l'erreur qui coûte le moins, et le dire.

Significatif n'est pas important. Le seuil d'importance pratique se tire des conséquences, et se fixe avant de regarder les données. Seul le tirage au sort autorise à parler de cause.

La recommandation : la réponse, la confiance, l'importance pratique, les limites, la condition de réexamen ; des mots à la mesure de la preuve.

3. CÔTÉ IA ET DATA

3.1 Remplacer un modèle en service

Le moteur de recherche d'un site d'offres d'emploi classe les offres avec un modèle. Sa nouvelle version, plus petite, coûte deux fois moins à faire tourner. Mais classe-t-elle aussi bien ? L'équipe a fixé sa règle avant le test : l'économie vaut une perte d'au plus 1 point sur la part des utilisateurs qui postulent à une offre trouvée par la recherche ; au-delà, on garde l'ancienne version. Elle tire au sort 60 000 utilisateurs : 30 000 gardent l'ancienne version, 30 000 reçoivent la nouvelle. Au bout d'une semaine, 24,0 % des premiers ont postulé, et 23,8 % des seconds. Chiffres fictifs.

La différence, −0,2 point, n'est pas significative : p-valeur ≈ 0,57. Son intervalle de confiance à 95 % va de −0,9 à +0,5 point : la perte, s'il y en a une, ne dépasse pas 0,9 point. De la borne basse à la borne haute, la décision est la même : adopter la nouvelle version. Le test ne montre pas de différence, et il suffit pourtant à décider. Il ne dit pas que les deux versions se valent : il dit que la perte reste sous le seuil fixé. Avec un intervalle de −1,3 à +0,9 point, la même estimation n'aurait rien tranché.

3.2 Le seuil d'un filtre anti-spam

Le filtre du chapitre 2 calcule, pour chaque message, la probabilité qu'il soit un spam. À partir de quelle probabilité l'écarter ? Les deux erreurs ne coûtent pas autant : un spam laissé dans la boîte de réception se supprime en une seconde ; un vrai message écarté, une offre ou une convocation, peut ne jamais être lu. Si l'on juge qu'écarter un vrai message coûte autant que laisser passer 20 spams, le seuil vaut $20 / (20 + 1) \approx 0{,}952$: le filtre n'écarte un message que s'il est un spam à plus de 95 %.

Un filtre trie 10 000 messages, dont 3 000 spams. Selon le seuil :

Seuil	Vrais messages écartés	Spams passés	Coût, en spams
0,5	70	150	70 × 20 + 150 = 1 550
0,9	20	330	20 × 20 + 330 = 730
0,99	4	700	4 × 20 + 700 = 780

Chiffres fictifs. Monter le seuil de 0,5 à 0,99 divise par plus de 17 les vrais messages écartés, et multiplie par plus de 4 les spams passés. Avec ces coûts, 0,9 fait le mieux des trois ; le meilleur seuil est proche de 0,952, si les probabilités du filtre sont calibrées (chapitre 5, section 3.2).

En 1998, M. Sahami, S. Dumais, D. Heckerman et E. Horvitz posent le tri du courrier indésirable comme une décision. Écarter à tort un message légitime, écrivent-ils, coûte en général bien plus que laisser passer un message indésirable. Ils n'écartent donc un message qu'au-delà de 99,9 %, pour refléter ce coût asymétrique des erreurs. Par la formule de la section 2.3, ce seuil revient à compter un vrai message écarté comme 999 spams passés, si les probabilités du filtre sont justes, ce dont ils doutent eux-mêmes (chapitre 2).

Source : M. Sahami, S. Dumais, D. Heckerman, E. Horvitz, « A Bayesian Approach to Filtering Junk E-Mail », AAAI-98 Workshop on Learning for Text Categorization, Madison, 1998, AAAI Technical Report WS-98-05, p. 55–62, aaai.org/papers/055-ws98-05-009.

4. AILLEURS AUSSI

Choisir une assurance. Assurer son téléphone contre la casse et le vol coûte 70 € par an. Le risque d'un sinistre dans l'année est de 0,1, et un téléphone neuf coûte 500 €. Chiffres fictifs. Sans assurance, la perte X vaut 500 € avec la probabilité 0,1, et 0 € sinon : E(X) = 50 €, moins que les 70 € de l'assurance, et σ(X) = 500 × √(0,1 × 0,9) = 150 €. En espérance, l'assurance fait perdre 20 € par an : c'est ce qui paie les frais de l'assureur. On s'assure pour réduire la dispersion, pas pour gagner. D'où la règle : assurer ce qu'on ne pourrait pas payer, l'incendie d'un logement, rare mais ruineux ; garder pour soi les pertes qu'on peut absorber, quand leur assurance coûte plus que leur espérance.

Fixer le seuil d'un dépistage. Au chapitre 2, section 4, un test positif ne donnait qu'environ 9 % de chances d'être malade : 0,092. Faut-il pour autant un second examen ? Un faux négatif, une maladie manquée, peut coûter une vie ; un faux positif coûte un examen de plus et quelques jours d'inquiétude. Si l'on juge le premier 99 fois plus grave, le seuil vaut 1 / (1 + 99) = 0,01 : un second examen se justifie dès 1 % de chances, et 0,092 le dépasse largement. Le même raisonnement fixe le seuil du test lui-même : un dépistage le place bas, pour manquer peu de malades, quitte à multiplier les faux positifs, que le second examen départage. Chiffres fictifs.

5. MÉTHODES ET PIÈGES

Une méthode en quatre temps

1. **Avant les données** : la décision, ses options, la règle de décision, le seuil d'importance pratique, les coûts des deux erreurs.

2. **Estimer** l'effet et son intervalle de confiance ; vérifier qu'un tirage au sort autorise à parler de cause.
3. **Décider pour chaque valeur de l'intervalle** : la décision tient-elle de la borne basse à la borne haute ?
4. **Écrire la recommandation** en cinq éléments : la réponse, la confiance, l'importance pratique, les limites, la condition de réexamen.

Les pièges

- **Juger sur la seule moyenne.** La rocade gagne 2 minutes en moyenne, et fait arriver trop tard à un examen une fois sur quatre. Regardez aussi l'écart-type, et la mauvaise issue.
- **Ignorer que les deux erreurs ne coûtent pas autant.** Un seuil de 0,5 par défaut suppose deux erreurs de même coût, ce qui est rare.
- **Confondre significatif et important.** Un écart significatif peut être trop petit pour compter : comparez son intervalle au seuil d'importance pratique, fixé d'avance.
- **Parler de cause sans tirage au sort.** Après une comparaison avant–après, ou entre des groupes formés d'eux-mêmes, on écrit « va de pair avec », jamais « fait augmenter ».
- **Taire les limites.** Une recommandation sans limites paraît plus sûre qu'elle ne l'est.
- **Recommander sans condition de réexamen.** Le client ne sait pas quand revenir sur sa décision.
- **Une précision trompeuse.** « 31,25 % », « p = 0,0000045 » : des décimales que les données ne portent pas. Un écart au dixième de point, et « p-valeur inférieure à 0,001 », suffisent.

6. EXERCICES

Six exercices, sur trois niveaux : appliquer (exercices 1 et 2), interpréter (exercices 3 et 4), résoudre un problème en contexte et rédiger (exercices 5 et 6). Chiffres fictifs ; écarts en points, au dixième. Les corrigés, aux mêmes numéros, sont dans le fascicule « MTH101 · Chapitre 6 · Corrigés », avec une réponse modèle pour les exercices 5 et 6. Cherchez d'abord, lisez ensuite.

Exercice 1 · Deux contrats

Un studio qui développe des applications hésite entre deux contrats pour son prochain projet. Le contrat A paie un forfait de 40 000 €, quoi qu'il arrive. Le contrat B partage les recettes : il rapporte 90 000 € avec la probabilité 0,4, 30 000 € avec la probabilité 0,4, et 0 € sinon.

1. Calculez l'espérance et l'écart-type de ce que rapporte chaque contrat.
2. Lequel rapporte le plus en moyenne ?
3. Pendant le projet, le studio doit payer 25 000 € de salaires. Avec quelle probabilité chaque contrat les couvre-t-il ?
4. Le studio n'a aucune réserve. Quel contrat lui recommandez-vous ? Et s'il avait 50 000 € de côté ?
5. Le studio signe chaque année dix contrats de ce genre, aux résultats indépendants. Le choix change-t-il ?

Exercice 2 · Le détecteur de chutes

Après un choc, une montre connectée estime la probabilité P que son porteur soit tombé ; au-delà d'un seuil, elle appelle un proche. Un appel pour rien, un faux positif, coûte un dérangement ; une chute sans appel, un faux négatif, coûte 50 fois plus. Sur une année, pour 1 000 porteurs, le fabricant a compté, selon le seuil :

Seuil	Appels pour rien	Chutes sans appel
0,01	900	2
0,05	300	6
0,2	80	15

1. À partir de quelle probabilité la montre doit-elle appeler ?
2. Après un choc, P = 0,05. Doit-elle appeler ? Et si P = 0,01 ?
3. Calculez le coût de chacun des trois seuils du tableau, en dérangements. Lequel choisir ?
4. Le fabricant monte le seuil à 0,2. Quel rapport entre les deux coûts ce choix suppose-t-il ? Qu'en pensez-vous ?

Exercice 3 · Quatre essais, un seuil

Une enseigne de jardinage teste quatre changements de son site, chacun par un test A/B : des clients tirés au sort voient l'ancienne ou la nouvelle version. Elle mesure la part des clients qui achètent. Sa règle, fixée avant les tests : adopter un changement s'il fait gagner au moins 1 point.

Changement	Clients par version	Écart	Intervalle de confiance à 95 %
1. Bouton d'achat plus visible	8 000	+2,1	de 1,4 à 2,8 points
2. Pages plus courtes	28 000	+0,6	de 0,3 à 0,9 point
3. Photos en gros plan	2 000	+1,2	de −0,4 à 2,8 points
4. Menu simplifié	10 000	−0,3	de −0,8 à 0,2 point

1. Lesquels de ces écarts sont significatifs au seuil de 5 % ?
2. Pour chaque changement, la décision tient-elle de la borne basse à la borne haute ? Laquelle ?
3. « Le changement 2 est significatif : adoptons-le », dit le responsable. Que lui répondez-vous ?
4. « Le changement 4 n'est pas significatif : il ne change rien, adoptons-le. » Qu'en dites-vous ?
5. Que proposez-vous pour le changement 3 ?

Exercice 4 · Une recommandation à reprendre

Une application de méditation a ajouté en mars un rappel du soir. En février, sans rappel, 18,0 % de ses 4 000 nouveaux utilisateurs étaient encore actifs au bout d'un mois ; en mars, avec le rappel, 20,5 % de ses 4 000 nouveaux utilisateurs. Un stagiaire écrit :

> « Le rappel du soir a fait augmenter la fidélité des utilisateurs de 13,8889 % (p = 0,00457). C'est prouvé : activez-le pour tous, sans aucun risque. »

1. Relevez au moins cinq défauts de cette recommandation.
2. Que peut-on dire, avec ces données, de l'effet du rappel ?
3. Proposez un protocole qui permettrait de conclure.
4. Réécrivez la première phrase pour qu'elle dise ce que les données montrent.

Exercice 5 · Le formulaire d'annonce

Un site de petites annonces a raccourci son formulaire de dépôt : deux champs de moins, qui servaient à vérifier les annonces. Pendant deux semaines, 24 000 utilisateurs qui commençaient une annonce ont été tirés au sort, 12 000 par formulaire : 61,0 % ont publié leur annonce avec l'ancien, 64,5 % avec le nouveau. Règle fixée avant le test : adopter le nouveau formulaire s'il fait publier au moins 2 points de plus.

1. Calculez la différence, son intervalle de confiance à 95 %, la statistique z et la p-valeur.
2. La décision tient-elle de la borne basse à la borne haute ?
3. Rédigez la recommandation au site en six lignes au plus : la réponse, la confiance, l'importance pratique, les limites, la condition de réexamen.

Exercice 6 · La page de dons

Une association a testé une nouvelle page de dons pendant un mois : 5 000 internautes tirés au sort, 2 500 par page ; 6,0 % ont donné avec l'ancienne, 7,2 % avec la nouvelle. La nouvelle page demande un abonnement annuel à un service de paiement en ligne. Règle fixée avant le test : l'adopter si elle fait donner au moins 1 point de plus. La page reçoit environ 5 000 internautes par mois.

1. Calculez la différence, son intervalle de confiance à 95 % et la p-valeur. La différence est-elle significative au seuil de 5 % ?
2. La décision tient-elle de la borne basse à la borne haute ?
3. Combien d'internautes par page faudrait-il à un nouveau test pour connaître la différence à 0,75 point près ? Combien de temps durerait-il ? Utilisez une marge de $1{,}96 \times \sqrt{(0{,}06 \times 0{,}94 / n + 0{,}072 \times 0{,}928 / n)}$.
4. Rédigez la recommandation à l'association en six lignes au plus.

7. POUR ALLER PLUS LOIN

Ressource	Ce que vous y trouverez
Google, Machine Learning Crash Course, module « Classification », page « Seuils et matrice de confusion », en français : developers.google.com/machine-learning/crash-course/classification/thresholding?hl=fr	Le seuil d'un classifieur et les deux erreurs, sur l'exemple du spam, avec un curseur pour déplacer le seuil.
A. Reinhart, *Statistics Done Wrong*, en anglais, lisible librement : statisticsdonewrong.com	« An introduction to data analysis » : significatif n'est pas important. « Statistical power and underpowered statistics » : des études trop petites, et le virage à droite au feu rouge.
M. Sahami et al., « A Bayesian Approach to Filtering Junk E-Mail », 1998, en anglais : aaai.org/papers/055-ws98-05-009	L'article de la section 3.2 : le tri du courrier indésirable posé comme une décision, avec des coûts d'erreur différents.